

Beskrivande statistik: hur man tabulerar, grafiskt representerar och numeriskt bearbetar data

Tabulering

- Ogrupperande data
En mängd rådata som inte blivit sorterad.
- Grupperande data
Data av samma storlek sammanförs.
Kan representeras i t.ex. en frekvenstabell.
- Klassindelade data
Data av ungetär samma storlek sammanförs.

Klasser

Klassindelning kan ske på olika sätt, men består dock alltid av:

- Klassgränser
En klassgräns utgörs av ett infimum g_i och ett supremum g_{i+1} för en klass i
 - Klassbredd
Klassbredden $h_i = g_{i+1} - g_i$ bör vara konstant för alla klasser s.a. $h_i = h \forall i$
 - Intervall
Ange intervallen för en klassgräns så alla värden entydligt kan föras till en klass, t.ex. $2.30 \leq x < 2.32$
 - Öppna klasser
Bör undvikas, t.ex. "alla observationer som är mindre än 2.32"
- Klassmitt
Klassmitten är medelvärdet av klassgränserna

Grafisk presentation

En grafisk presentation av en mängd data kan göras med hjälp av:

- Stolpdiagram
- Histogram
- Boxplott / Lådogram

Frekvenstabeller

Gör stor mängd data lättöverskådlig.
Brukar innehålla följande:

- Olika förekommande värden
Datapunkter som grupperas/klassindelas beroende på deras storlek, betecknat y_i
- Klass
Värden y_i kan delas in i " i " olika klasser, där $i = 1, 2, \dots$ och i :a klassen representerar det lägsta förekommande värdet oftast
- Absolut frekvens
Antalet datapunkter i en klass, betecknat f_i
- Relativ frekvens
Absolut frekvens per totala antalet datapunkter (n), betecknat p_i
 $\therefore p_i = f_i/n$ och anges ofta i %

→

Läges- och spridningsmått (Ogrupperade data)

a) Lägesmått

Anger hur stor en storhet är i medeltal. Kan använda t.ex.

i) Geometriskt medelvärde, G

Medelvärde för normaliserade resultat, används vid uträkning av genomsnittlig ränta

$$\bar{x} = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$$

ii) Harmoniskt medelvärde, H

Inverterade värdet av det aritmetiska medelvärdet, används vid tillväxtfenomen

$$\bar{x} = \left(\frac{1}{n} \cdot \sum_{i=1}^n x_i^{-1} \right)^{-1}$$

iii) Kvadratisk medelvärde, Q (RMS)

Anger variationerna hos en storhets belopp, ett generaliserat medelvärde, används inom elektrotekniken

$$x_{rms} = \sqrt{\frac{1}{n} (x_1^2 + x_2^2 + \dots + x_n^2)}$$

Överkurs
för nowiv) Aritmetiska medelvärde, A

Genomsnittliga värdet av en datamängd, används oftast som lägesmått

$$\bar{x} = \frac{1}{n} \cdot \sum_{i=1}^n x_i$$

← WE LIKE

v) Median

Används för att minska avvikande värdenas påverkan

$$\bar{x}_Q \leq \bar{x}_A \leq \bar{x}_G \leq \bar{x}_H$$

b) Spridningsmått

Anger hur mycket en storhet skiljer sig åt

i) (Stickprovs) varians

Används ibland pga önskvärda egenskaper (bokens words not mine)

$$s^2 = \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})^2$$

ii) Standardavvikelse

Kvadratroten av variansen

$$s = \sqrt{\frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})^2}$$

iii) Kvartiler (medianuppdelning)

Beräkna undre kvartilen \tilde{x}_{undre} och övre kvartilen $\tilde{x}_{\text{övre}}$ och ta medianen ur resp. kvartilKvartilavstånd: $\tilde{x}_{\text{övre}} - \tilde{x}_{\text{undre}}$
Kvartilsintervall: $(\tilde{x}_{\text{undre}}, \tilde{x}_{\text{övre}})$

iv) Variationsbredd

Används vid små datamängder, där variationsbredden R är differansen mellan det största och minsta värdet, x_{\max} resp. x_{\min} $R = x_{\max} - x_{\min}$
Variationsintervallet: (x_{\min}, x_{\max}) v) Kvadratsumman kring \bar{x}_A

$$Q = (n-1)s^2 = \sum_{j=1}^n (x_j - \bar{x})^2 = \sum x_j^2 - \frac{1}{n} \left(\sum x_j \right)^2$$

vi) Standardavvikelse i % av \bar{x}
Variationskoefficienten $100 \cdot s/\bar{x} \%$

Läges- och spridningsmått *formering*

För grupperade data kan man behandla den som för ogrupperade data, dock är det mer praktiskt att använda informationen från en frekvenstabell.

a) Lägesmått: medelvärde

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k f_i y_i$$

där $\begin{cases} k = \text{antal grupper} \\ f_i = \text{absolut frekvens} \\ y_i = \text{data av viss storlek} \end{cases}$

b) Spridningsmått: kvadratsumma

$$Q = \sum_{i=1}^k f_i (y_i - \bar{x})^2 = \sum f_i y_i^2 - \frac{1}{n} \left(\sum f_i y_i \right)^2$$

För klassindelade data approximeras denna till en grupperad datamängd där varje värde x_i ersätts med klassmitten y_i i den klass värdet hamnat i.

Korrelation

Undersöker sambandet mellan parade data och anger ett mått på sambandet. De vanligaste mättsambanden är:

a) Kovarians

Mellan x - och y -värden i en datamängd är kovariansen:

$$C_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

b) Korrelationskoefficienten

Då s_x och s_y är standardavvikelsen för x - resp. y -värde är korrelationskoefficienten:

$$r = \frac{C_{xy}}{s_x s_y}$$

Dessa kan endast definieras för numerisk data!

Def (utfall): Resultatet av ett slumpmässigt försök kallas ett utfall (w_1, w_2, \dots).

Notation (U/Ω): Minst en av händelserna inträffar:
 $\bigcup_{i=1}^n A_i = A_1 \cup A_2 \cup \dots \cup A_n$

Def (utfallsrum): Mängden av alla möjliga utfall kallas utfallsrummet (Ω)

Alla händelserna inträffar:
 $\bigcap_{i=1}^n A_i = A_1 \cap A_2 \cap \dots \cap A_n$

Def (händelse): En händelse är en specifik samling av utfall (A, B, C, \dots)

Def (parvis oförenliga, disjunkta): Händelserna A_1, \dots, A_n kan sägas vara parvis oförenliga om alla par A_i och A_j är disjunkta (= oförenliga), dvs det är omöjligt att händelserna inträffar samtidigt

Def (diskret/ändligt/kontinuerligt utfallsrum): Om antalet utfall är ändligt eller uppräknligt oändligt sägs Ω vara ett diskret utfallsrum. Om antalet är ändligt sägs Ω vara ett ändligt utfallsrum. Om antalet är varken eller sägs Ω vara ett kontinuerligt utfallsrum.

Def (komplement): Komplementet till en händelse A är $A^c = \Omega \setminus A$, kan också betecknas \bar{A} .

Sats (De Morgans lagar): Låt A , B och C vara händelser. Då gäller följande likheter:

$$(i) A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

$$(ii) A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

$$(iii) \left(\bigcup_{i=1}^n A_i \right)^* = \bigcap_{i=1}^n A_i^*$$

$$(iv) \left(\bigcap_{i=1}^n A_i \right)^* = \bigcup_{i=1}^n A_i^*$$

Def (sannolikhet): För en händelse A finns det ett tal $P(A)$ kallat **sannolikheten** för A . $P(A)$ väljs s.a. den relativa frekvensen vid ett stort antal försök hamnar nära $P(A)$. Typ konvergerar. $P(\cdot)$ kallas **sannolikhetsmåttet**.

Def (frekvenstolkning): För $P(A)=a$ där $a \in [0, 1]$ blir **frekvenstolkningen**: vid ett stort antal försök blir den relativa frekvensen av A nog ungefär lika med a .

Sats (Kolmogorovs axiomsystem): För $P(\cdot)$ ska följande axiom vara uppfyllda:

- (i) För varje händelse A gäller att $0 \leq P(A) \leq 1$
- (ii) För hela utfallsrummet Ω gäller att $P(\Omega) = 1$
- (iii) **Additionssatsen**: Om A_1, A_2, \dots är en diskret följd av parvis oförenliga händelser gäller att $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$

Sats (komplementsatsen): För komplementet A^* till A gäller att $P(A^*) = 1 - P(A)$

Sats (additionssatsen för två händelser): För två händelser A och B gäller att $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Sats (Booles olikhet): För två händelser A och B gäller att $P(A \cup B) \leq P(A) + P(B)$

Def (liktformigt sannolikhetsmått): Om $P(\omega_i) = \frac{1}{m}$ då $i=1, \dots, m$ föreligger ett **liktformigt sannolikhetsmått**

Sats (den klassiska sannolikhetsdefinitionen): Vid liktformigt sannolikhetsmått är sannolikheten för en viss händelse lika med kvoten mellan antalet gynsamma fall g för händelsen och antalet möjliga fall m ; $\therefore P(A) = g/m$.

Sats (multiplikationsprincipen): Om åtgärd 1 kan utföras på a_1 olika sätt och åtgärd 2 på a_2 olika sätt finns det $a_1 a_2$ olika sätt att utföra båda på.

Sats (dragning med återlämning): Dragning med återlämning av k element ur n med hänsyn till ordning kan ske på n^k olika sätt.

Sats (dragning utan återlämning): Dragning utan återlämning av k element ur n med hänsyn till ordning kan ske på $n(n-1) \cdot \dots \cdot (n-k+1)$ olika sätt.

$$P(A) = \frac{n!}{(n-k)! k!}$$

Antalet sätt n element kan ordnas på är lika med $n(n-1) \cdot \dots \cdot 2 \cdot 1 = n!$, kallat **n -fakultet**

(5)

boken
SF1922
20 03 18

Sats (dragning utan återläggning): Dragning utan återlämning av k element ur n utan hänsyn till ordning kan ske på $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ olika sätt.

Sats (binomialteoremet): För varje positivt heltal n och godtyckliga tal x och y gäller att

$$(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}$$

Uppdatering: mängdlära

Utfallsrummet



Grundmängden

Händelsen A:
A inträffar




Delmängden A

Komplementära
händelsen till A:
A inträffar inte




Komplementet A^* till A

Unionhändelse $A \cup B$:
A eller B eller
båda inträffar



Unionen $A \cup B$

Snitthändelsen $A \cap B$:
både A och B
inträffar



Snittet $A \cap B$

A och B oförenliga
händelser: A och
B kan inte inträffa
samtidigt



A och B disjunkta